

自动驾驶与机器人中的 SLAM技术


LIO系统





Contents

- 紧耦合LIO系统
- 基于预积分的LIO系统
- 将LIO系统用于建图前端





Contents

紧耦合LIO系统



紧耦合LIO系统

□ 上节课介绍了松耦合LIO系统

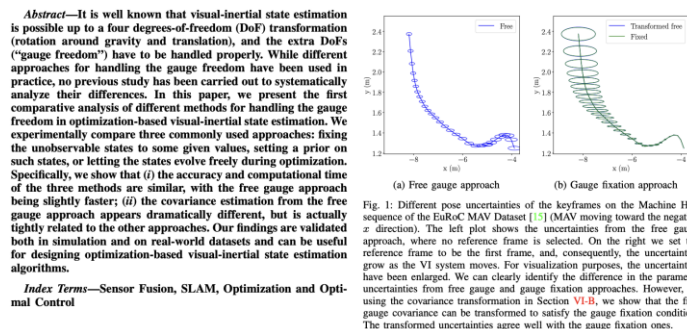
- 基于ESKF + incremental NDT LO的位姿融合

□ 松耦合LIO系统的问题：

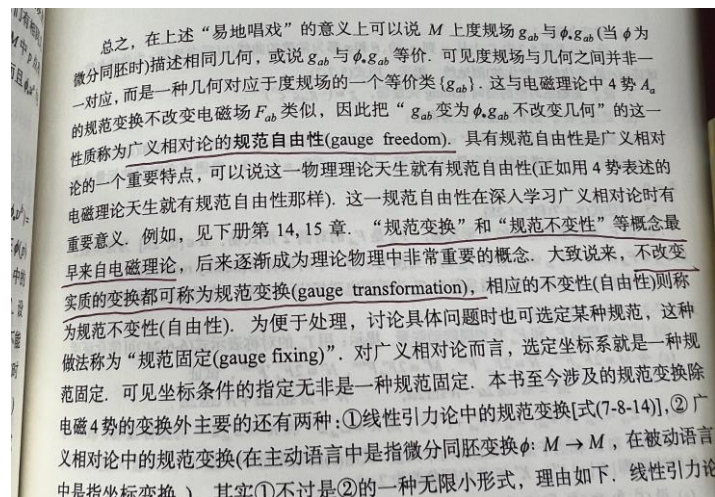
- LO和IMU部分都是独立运行的，虽然容易模块化，但二者均可能有失效情形，例如：IMU在没有融合Pose时会很快发散，LO在点云形状不好的时候存在退化；
- 当其中一个模块失效，松耦合系统通过重置该模块来处理失效情形，可能导致系统整体输出不连续，并且生效判定也可能存在异常。其数学解释是：单个模块的状态估计存在额外自由度（gauge freedom），仅凭模块自己并不能固定。
- 注：gauge freedom这个词在其他领域也有应用，但在SLAM领域主要指状态估计的自由度，相当于EKF的能观维度或者优化的H阵的非零特征值个数。

On the Comparison of Gauge Freedom Handling in Optimization-based Visual-Inertial State Estimation

Zichao Zhang, Guillermo Gallego, Davide Scaramuzza



SLAM中的gauge freedom



GR中的gauge freedom



紧耦合LIO系统

□ 而在紧耦合系统中：

- 因为各模块残差被放到了同一个问题中，整个状态估计自由度由各模块一起决定；
- 于是，理论上认为，当单个模块失效时，其状态估计的有效维度仍然能保持在一定限度内。

□ 例如：LO退化场景

- 松耦合：LO输出的Pose不稳定，导致滤波器融合的位姿异常。解决方法：在LO中引入退化检测，在退化时单独处理；
- 紧耦合：LO的残差与IMU残差在同一问题中，IMU给定了位姿（或者轮速的速度）分布，LO的残差不会离该分布太远；
- 一般来说，只要在同一问题中考虑各传感器内部残差，就视为紧耦合系统，例如紧耦合LIO、紧耦合GINS、紧耦合VIO，等等。



紧耦合LIO系统

□ 基于EKSF的紧耦合LIO系统

- 可以将点云残差（ICP、点面、点线、NDT等）融入ESKF观测方程，而不是在IMU预测位姿上单独求解ICP或NDT（可能随点云退化而发散）；
- 由于ICP、NDT等算法均需要迭代，应该将ESKF改成迭代版本：iterated error state extended Kalman filter（**IESEKF**，简记**IEKF**）；
- 迭代过程中还要求解最近邻；
- 下面以NDT为例，推导基于NDT观测的IEKF，并解释IEKF中的迭代观测与纯NDT迭代之间的联系。



紧耦合LIO系统

□ IEKF推导

□ 状态变量: $x = [p, v, R, b_g, b_a, g]^T \in \mathcal{M}$.

□ 运动过程（直接写离散的，不从连续时间推了）：

$$p(t + \Delta t) = p(t) + v\Delta t + \frac{1}{2} (R(\tilde{a} - b_a)) \Delta t^2 + \frac{1}{2} g \Delta t^2,$$

$$v(t + \Delta t) = v(t) + R(\tilde{a} - b_a)\Delta t + g\Delta t,$$

$$R(t + \Delta t) = R(t) \text{Exp}((\tilde{\omega} - b_g)\Delta t),$$

$$b_g(t + \Delta t) = b_g(t),$$

$$b_a(t + \Delta t) = b_a(t),$$

$$g(t + \Delta t) = g(t).$$

协方差的预测: $P_{\text{pred}} = F P F^T + Q,$

$$F = \begin{bmatrix} I & I\Delta t & 0 & 0 & 0 & 0 \\ 0 & I & -R(\tilde{a} - b_a)^{\wedge} \Delta t & 0 & -R\Delta t & I\Delta t \\ 0 & 0 & \text{Exp}(-(\tilde{\omega} - b_g)\Delta t) & -I\Delta t & 0 & 0 \\ 0 & 0 & 0 & I & 0 & 0 \\ 0 & 0 & 0 & 0 & I & 0 \\ 0 & 0 & 0 & 0 & 0 & I \end{bmatrix}.$$


预测后得到名义状态的 $x_{\text{pred}}, P_{\text{pred}}$ ，预测不参与迭代



紧耦合LIO系统

□ IEKF观测方程

1. 观测方程现在有一个迭代过程，记迭代次数为 k
2. 迭代从pred位置出发，每次计算一个 $\delta \mathbf{x}_k$
3. 每次迭代需要计算最近邻、线性化矩阵和卡尔曼增益，记为 $\mathbf{K}_k, \mathbf{H}_k$
4. 原则上，也需要计算每次迭代的 \mathbf{P} 阵。但是，实际上可以将预测的 \mathbf{P} 阵投影到当前工作点，形成先验分布，所以方差部分只需在迭代结束时结算即可
5. 于是，在第 k 次迭代时，可以看成：名义状态为 \mathbf{x}_k ，误差状态为0，协方差为投影后的 \mathbf{P}_{pred} ，目标是计算 $\delta \mathbf{x}_k$
6. 最后，ESKF的观测方程个数是固定的，而LIO的IEKF观测方程是可变的（取决于最近邻点数），且维度远大于运动方程





紧耦合LIO系统

□ 在第 k 次迭代中，我们有工作点 \mathbf{x}_k

□ 首先，将预测的 P 阵（即 \mathbf{x}_0 处）投影到当前工作点，投影方式同第3章的ESKF：

$$\mathbf{J}_k = \text{diag}(\mathbf{I}_3, \mathbf{I}_3, \mathbf{J}_\theta, \mathbf{I}_3, \mathbf{I}_3, \mathbf{I}_3), \quad \mathbf{J}_\theta = \mathbf{I} - \frac{1}{2}\delta\theta_k^\wedge, \quad \delta\theta_k = \text{Log}(\mathbf{R}_0^\top \mathbf{R}_k).$$

□ 此时预测点的给定的先验分布为：

$$\delta\mathbf{x}_k \sim \mathcal{N}(\mathbf{0}, \mathbf{J}_k \mathbf{P}_{\text{pred}} \mathbf{J}_k^\top).$$

□ 现在利用EKF公式计算误差状态：

$$\mathbf{K}_k = \mathbf{P}_k \mathbf{H}_k^\top (\mathbf{H}_k \mathbf{P}_k \mathbf{H}_k^\top + \mathbf{V})^{-1},$$

$$\delta\mathbf{x}_k = \mathbf{K}_k (\mathbf{z} - \mathbf{h}(\mathbf{x}_k)).$$

□ 如果没有收敛，那么不需要计算 P 阵的更新，因为下次迭代是从预测位置投过来的

□ 如果收敛了，那么计算协方差阵：

$$\mathbf{P}_{k+1} = (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{J}_k \mathbf{P}_{\text{pred}} \mathbf{J}_k^\top.$$

即：从协方差角度来说，只有最后一次迭代是有效的，其他迭代只是改变了工作点



紧耦合LIO系统

□ 此时IEKF的观测方式相当于求解最小二乘：

$$\delta \mathbf{x}_k = \arg \min_{\delta \mathbf{x}} \underbrace{\|\mathbf{z} - \mathbf{H}_k(\mathbf{x}_k \boxplus \delta \mathbf{x})\|_{\mathbf{V}}^2}_{\text{点云残差}} + \underbrace{\|\delta \mathbf{x}_k\|_{\mathbf{P}_k}^2}_{\text{先验残差}}.$$

点云残差

先验残差

注意：这是一种相对简单的做法，和[1][2]均有差别，其中[1]更复杂，并非将预测协方差投到当前工作点，[2]则不需要考虑迭代时观测方程会变的问题：

[1]里的记法：

$$\begin{aligned} \delta \mathbf{x}_j^o &= -\mathbf{J}_{k+1}^j (\mathbf{x}_{k+1|k+1}^j \boxminus \mathbf{x}_{k+1|k}) \\ &\quad + \mathbf{K}_{k+1}^j (\mathbf{r}_{k+1}^j + \mathbf{H}_{k+1}^j \mathbf{J}_{k+1}^j (\mathbf{x}_{k+1|k+1}^j \boxminus \mathbf{x}_{k+1|k})) \\ \mathbf{K}_{k+1}^j &= (\mathbf{Q}_{k+1}^j)^{-1} (\mathbf{H}_{k+1}^j)^T \bar{\mathcal{R}}_{k+1}^{-1} \\ &= \mathbf{J}_{k+1}^j \mathbf{P}_{k+1|k} (\mathbf{J}_{k+1}^j)^T (\mathbf{H}_{k+1}^j)^T (\mathbf{S}_{k+1}^j)^{-1} \\ \mathbf{Q}_{k+1}^j &= (\mathbf{H}_{k+1}^j)^T \bar{\mathcal{R}}_{k+1}^{-1} \mathbf{H}_{k+1}^j + (\mathbf{J}_{k+1}^j)^{-T} \mathbf{P}_{k+1|k}^{-1} (\mathbf{J}_{k+1}^j)^{-1} \\ \mathbf{S}_{k+1}^j &= \mathbf{H}_{k+1}^j \mathbf{J}_{k+1}^j \mathbf{P}_{k+1|k} (\mathbf{J}_{k+1}^j)^T (\mathbf{H}_{k+1}^j)^T + \bar{\mathcal{R}}_{k+1} \end{aligned}$$

$$\begin{aligned} \mathbf{r}_{k+1}^j &\triangleq \mathbf{z}_{k+1} \boxminus \mathbf{h}(\mathbf{x}_{k+1|k+1}^j, \mathbf{0}) \\ &= \mathbf{h}(\mathbf{x}_{k+1}, \mathbf{v}_{k+1}) \boxminus \mathbf{h}(\mathbf{x}_{k+1|k+1}^j, \mathbf{0}) \\ &= \mathbf{h}(\mathbf{x}_{k+1|k+1}^j \boxplus \delta \mathbf{x}_j, \mathbf{v}_{k+1}) \boxminus \mathbf{h}(\mathbf{x}_{k+1|k+1}^j, \mathbf{0}) \\ &\approx \mathbf{D}_{k+1}^j \mathbf{v}_{k+1} + \mathbf{H}_{k+1}^j \delta \mathbf{x}_j \\ \delta \mathbf{x}_j &\sim \mathcal{N}(-\mathbf{J}_{k+1}^j (\mathbf{x}_{k+1|k+1}^j \boxminus \mathbf{x}_{k+1|k}), \mathbf{J}_{k+1}^j \mathbf{P}_{k+1|k} (\mathbf{J}_{k+1}^j)^T) \\ \mathbf{P}_{k+1}^j &= (\mathbf{Q}_{k+1}^j)^{-1} \\ &= (\mathbf{I} - \mathbf{K}_{k+1}^j \mathbf{H}_{k+1}^j) \mathbf{J}_{k+1}^j \mathbf{P}_{k+1|k} (\mathbf{J}_{k+1}^j)^T \end{aligned}$$

[1] He D, Xu W, Zhang F. Kalman filters on differentiable manifolds[J]. arXiv preprint arXiv:2102.03804, 2021.

[2] Barfoot T D. State estimation for robotics[M]. Cambridge University Press, 2017.



紧耦合LIO系统

□ 考虑观测方程维度较高，需要变换公式

原先的更新方程：

H_k 为 $N \times 18$ ， N 为匹配点云个数；

有一个 $N \times N$ 的矩阵求逆

$$\mathbf{K}_k = \mathbf{P}_k \mathbf{H}_k^\top (\mathbf{H}_k \mathbf{P}_k \mathbf{H}_k^\top + \mathbf{V})^{-1},$$

$$\delta \mathbf{x}_k = \mathbf{K}_k (\mathbf{z} - \mathbf{h}(\mathbf{x}_k)).$$

利用Sherman-Morrison-Woodbury恒等式：

$$\mathbf{A} \mathbf{B} (\mathbf{D} + \mathbf{C} \mathbf{A} \mathbf{B})^{-1} = (\mathbf{A}^{-1} + \mathbf{B} \mathbf{D}^{-1} \mathbf{C})^{-1} \mathbf{B} \mathbf{D}^{-1},$$

代入后：

$$\mathbf{K}_k = (\mathbf{P}_k^{-1} + \mathbf{H}_k^\top \mathbf{V}^{-1} \mathbf{H}_k)^{-1} \mathbf{H}_k^\top \mathbf{V}^{-1}.$$

此处的逆矩阵为 18×18

这可以大幅减少卡尔曼增益中求逆的维度，本质就是一个SMW变换。



紧耦合LIO系统

□ 下面来说明IEKF和纯激光NDT的关系

□ NDT变换：设某个点对应的体素中，产生了残差和协方差：

$$\mathbf{e}_j = \mathbf{r}_j^\top \boldsymbol{\Sigma}_j^{-1} \mathbf{r}_j. \quad \text{当然残差为: } \mathbf{R}\mathbf{q}_i + \mathbf{t} - \boldsymbol{\mu}_i,$$

□ 雅可比矩阵，也就是线性化系数为：

$$\frac{\partial \mathbf{r}_j}{\partial \mathbf{R}} = -\mathbf{R}\mathbf{q}_j^\wedge, \quad \frac{\partial \mathbf{r}_j}{\partial \mathbf{t}} = \mathbf{I}. \quad \mathbf{J}_j = \left[\frac{\partial \mathbf{r}_j}{\partial \mathbf{t}}, \mathbf{0}_3, \frac{\partial \mathbf{r}_j}{\partial \mathbf{R}}, \mathbf{0}_3, \mathbf{0}_3, \mathbf{0}_3 \right]$$

□ 对应到IEKF中，等效于 H 阵的第 j 行：

$$\mathbf{H}_k = \begin{bmatrix} \cdots \\ \mathbf{J}_j \\ \cdots \end{bmatrix}, \quad \mathbf{V} = \text{diag}(\cdots, \boldsymbol{\Sigma}_j, \cdots).$$



紧耦合LIO系统

□ 对匹配点云残差求平方和，并求最小二乘，即为 $\sum_i (J_i^\top \Sigma_i^{-1} J_i) \Delta x = - \sum_i J_i^\top \Sigma_i^{-1} e_i.$

□ 同时，卡尔曼增益为：

$$K_k = (P_k^{-1} + H_k^\top V^{-1} H_k)^{-1} H_k^\top V^{-1}.$$

右侧部分：

中间部分代入：

$$H_k = \begin{bmatrix} \cdots, \\ J_j, \\ \cdots \end{bmatrix}, \quad V = \text{diag}(\cdots, \Sigma_j, \cdots).$$

$$H_k^\top V^{-1} (z - h(x_k)) = [\cdots, J_j^\top, \cdots] \text{diag}(\cdots, \Sigma_j^{-1}, \cdots) \begin{bmatrix} \cdots \\ r_j \\ \cdots \end{bmatrix},$$
$$= \sum_j J_j^\top \Sigma_j^{-1} r_j.$$

得到：

$$H_k^\top V^{-1} H_k = \sum_j J_j^\top \Sigma_j^{-1} J_j.$$



紧耦合LIO系统

□ NDT求了什么？

$$\sum_i (J_i^\top \Sigma_i^{-1} J_i) \Delta x = - \sum_i J_i^\top \Sigma_i^{-1} e_i.$$

EKF求了什么？ $K_k = (P_k^{-1} + H_k^\top V^{-1} H_k)^{-1} H_k^\top V^{-1}.$

$$\delta x_k = K_k (z - h(x_k)).$$

$$\delta x_k = (P_k^{-1} + H_k^\top V^{-1} H_k)^{-1} H_k^\top V^{-1} (z - h(x_k))$$

$$H_k^\top V^{-1} H_k = \sum_j J_j^\top \Sigma_j^{-1} J_j.$$

$$\begin{aligned} H_k^\top V^{-1} (z - h(x_k)) &= [\cdots, J_j^\top, \cdots] \text{diag}(\cdots, \Sigma_j^{-1}, \cdots) \begin{bmatrix} \cdots \\ r_j \\ \cdots \end{bmatrix}, \\ &= \sum_j J_j^\top \Sigma_j^{-1} r_j. \end{aligned}$$

所以IEKF实际上就是一个带着先验分布的NDT!

类似的结论也可以推广至EKF+ICP中。



紧耦合LIO系统

□ 基于IEKF的NDT LO实现

□ NDT部分计算：

$$H_k^T V^{-1} H_k = \sum_j J_j^T \Sigma_j^{-1} J_j. \quad 18 \times 18$$

$$H_k^T V^{-1} (z - h(x_k)) = [\cdots, J_j^T, \cdots] \text{diag}(\cdots, \Sigma_j^{-1}, \cdots) \begin{bmatrix} \cdots \\ r_j \\ \cdots \end{bmatrix},$$
$$= \sum_j J_j^T \Sigma_j^{-1} r_j. \quad 18 \times 1$$

EKF部分融入之后，计算：

$$Q_k = (P_k^{-1} + H_k^T V^{-1} H_k)^{-1}$$
$$\delta x_k = Q_k H_k^T V^{-1} r_k,$$
$$P_{k+1} = (I - Q_k H_k^T V^{-1} H_k) P_k.$$

只需在收敛时计算

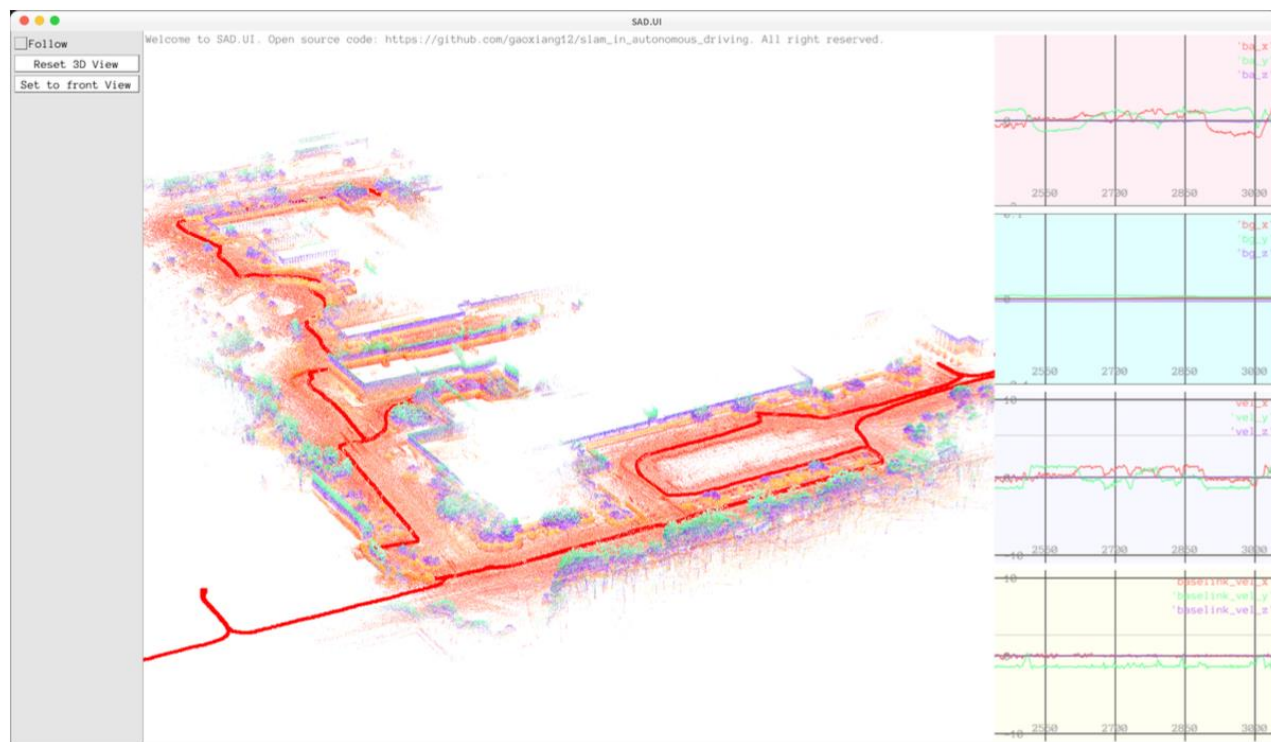
□ 地图部分仍然使用增量NDT更新（没有local map点云，更简洁）



紧耦合LIO系统

▣ 代码实现及结果讨论

▣ 框架部分可直接沿用LooselyLIO，保留数据同步、去畸变等代码



效率上和松耦合接近

松耦合：NDT迭代+EKF融合6自由度pose

紧耦合：EKF直接融合NDT残差，也需要迭代



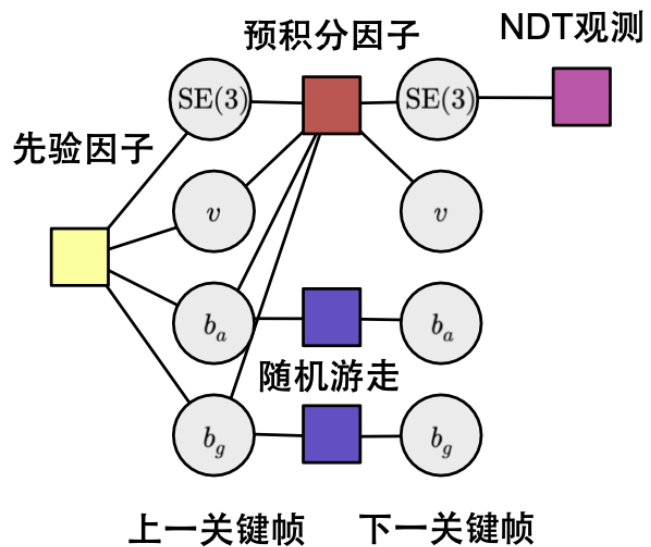
预积分LIO系统



预积分LIO系统

- 在第3、4章，我们实现了基于ESKF和预积分的GINS系统，同样可以推广至LIO系统。
- 由于我们没有直接实现NDT factor (NDT edge)，现在主要演示用图优化来融合NDT LO的位姿效果（类似于GINS中融GNSS观测）。

图模型：





预积分LIO系统

□ 预积分LIO实现要点：

1. 预积分因子较为灵活，需要增加先验因子；
2. NDT观测给定位姿（也可以写成NDT factor，把最近邻搜索写在内部，但效率较低，且数量不可变）；
3. 预积分将预测位姿传递给LO；
4. 但LO的观测位姿与GNSS有本质区别：GNSS观测有固定精度，而LO有两个缺点：(1) 位姿是发散的 (2) 当预测位姿不准时，也可能给不出正确结果。



预积分LIO系统

- 先验因子与边缘化
- 之前在第4章跳过去的部分（在第4章介绍，内容太多了）
- 边缘化是指从联合分布得到一部分随机变量分布的过程

联合分布

$$p(\mathbf{x}, \mathbf{y}) = \mathcal{N} \left(\begin{bmatrix} \boldsymbol{\mu}_x \\ \boldsymbol{\mu}_y \end{bmatrix}, \begin{bmatrix} \boldsymbol{\Sigma}_{xx} & \boldsymbol{\Sigma}_{xy} \\ \boldsymbol{\Sigma}_{yx} & \boldsymbol{\Sigma}_{yy} \end{bmatrix} \right)$$

Schur分解（左右高斯消元）

$$\begin{bmatrix} \boldsymbol{\Sigma}_{xx} & \boldsymbol{\Sigma}_{xy} \\ \boldsymbol{\Sigma}_{yx} & \boldsymbol{\Sigma}_{yy} \end{bmatrix} = \begin{bmatrix} \mathbf{1} & \boldsymbol{\Sigma}_{xy} \boldsymbol{\Sigma}_{yy}^{-1} \\ \mathbf{0} & \mathbf{1} \end{bmatrix} \begin{bmatrix} \boldsymbol{\Sigma}_{xx} - \boldsymbol{\Sigma}_{xy} \boldsymbol{\Sigma}_{yy}^{-1} \boldsymbol{\Sigma}_{yx} & \mathbf{0} \\ \mathbf{0} & \boldsymbol{\Sigma}_{yy} \end{bmatrix} \begin{bmatrix} \mathbf{1} & \mathbf{0} \\ \boldsymbol{\Sigma}_{yy}^{-1} \boldsymbol{\Sigma}_{yx} & \mathbf{1} \end{bmatrix}$$

$$\mathbf{K}_k = \mathbf{P}_{k,\text{pred}} \mathbf{C}_k^\top (\mathbf{C}_k \mathbf{P}_{k,\text{pred}} \mathbf{C}_k^\top + \mathbf{Q}_k)^{-1}.$$

$$\mathbf{P}_k = (\mathbf{I} - \mathbf{K}_k \mathbf{C}_k) \mathbf{P}_{k,\text{pred}}.$$

可对比KF协方差部分

实际上边缘化了 \mathbf{x}_{k-1} ，详见状态估计3.3.2节

$$p(\mathbf{x}, \mathbf{y}) = p(\mathbf{x}|\mathbf{y})p(\mathbf{y}) \quad \text{联合分布}$$

$$p(\mathbf{x}|\mathbf{y}) = \mathcal{N}(\boldsymbol{\mu}_x + \boldsymbol{\Sigma}_{xy} \boldsymbol{\Sigma}_{yy}^{-1} (\mathbf{y} - \boldsymbol{\mu}_y), \boldsymbol{\Sigma}_{xx} - \boldsymbol{\Sigma}_{xy} \boldsymbol{\Sigma}_{yy}^{-1} \boldsymbol{\Sigma}_{yx})$$

$$p(\mathbf{y}) = \mathcal{N}(\boldsymbol{\mu}_y, \boldsymbol{\Sigma}_{yy})$$

条件分布





预积分LIO系统

□ 优化问题中的边缘化

□ 对优化问题来说，协方差实际上就是左侧的Hessian之逆

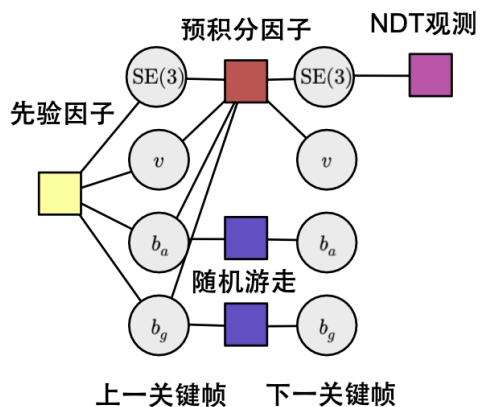
$$\sum_i (J_i^\top \Sigma_i^{-1} J_i) \Delta x = - \sum_i J_i^\top \Sigma_i^{-1} e_i.$$

Hessian阵

对应KF公式: $\hat{P}_k^{-1} \hat{x}_k = \check{P}_k^{-1} \check{x}_k + C_k^\top R_k^{-1} y_k$

$$\underbrace{(H^\top W^{-1} H)}_{\text{协方差的逆}} \underbrace{\hat{x}}_{\text{均值}} = \underbrace{H^\top W^{-1} z}_{\text{信息向量}}$$

所以，对Hessian阵进行Schur分解后，可得当前时刻状态的条件分布，即对过去时刻进行边缘化。



预积分图优化共两个时刻状态，所以对前一个时刻状态进行边缘化即可

此时得到后一个时刻的先验分布

Hessian阵需要调用g2o的雅可比阵和信息矩阵来获得



预积分LIO系统

□ 预积分的代码实现和效果



将LIO系统用于建图前端



将LIO系统用于建图前端

□ LIO系统的用途

□ 在部分场景下，可以作为一种Odom类的位姿来源

□ Odom类位姿的局限性：

1. 跟真值相比，位姿最终是发散的（尽管EKF的P阵不会发散，因为相信地图点云是正确的）；
2. 不可避免地存在累积误差，误差大小取决于器件精度和算法，累积误差可能体现在高度上，也可能体现在角度或者水平位置上；
3. 用于建图的话，必然存在重影现象，但是LO/LIO可以作为建图软件的前端使用。

□ 大部分自动驾驶定位功能都通过离线建图+在线定位实现，而不是在线SLAM方式

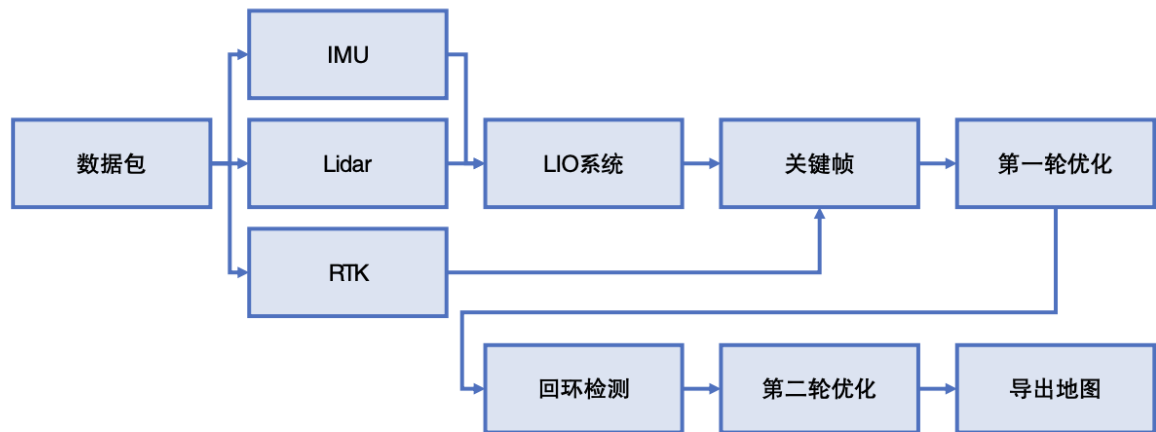
□ LO/LIO可以用于建图的前端或者定位的Odom观测



将LIO系统用于建图前端

□ 离线建图相比在线建图的好处

1. 结果更加确定，没有线程间调度和等待关系
2. 点云质量可以有更充分的保证
3. 框架设计更加灵活
4. 任务层面和关键步骤层面都可以实现并发
5. 可以做成云计算+服务器模式
6. 可以接入后处理感知算法，实现更多自动化功能




本课程利用LIO作为前端



将LIO系统用于建图前端

- 建图端使用LIO的演示
- 下节课介绍后端优化、GNSS融合与异常值去除，并发的回环检测、地图切分等功能



LIO虽然有较好的相对精度，但点云仍然存在明显重影



习题

1. 如果在IEKF中引入点面ICP作为观测方程，请说明观测方程的具体处理方式，以及IEKF和纯激光ICP之间的关系。
2. 实现基于点面ICP的IEKF LIO系统，给出实现代码和实验展示（注意local map的处理方式和NDT有所不同）。

感谢聆听！
Thanks for Listening

